

Лабораторная работа №6

Разработка процессора языка разметки документа.

Теоретическая часть

Язык разметки в компьютерной терминологии – набор символов или последовательностей, вставляемых в текст для передачи информации о его выводе или строении. Языки разметки используются везде, где требуется вывод форматированного текста: в типографии (SGML, TeX, PS, PDF), пользовательских интерфейсах компьютеров (troff, Microsoft Word, OpenOffice), Всемирной сети (HTML, XML).

Например, TeX – система компьютерной вёрстки, разработанная американским почётным профессором Дональдом Кнудом в целях создания компьютерной типографии. В неё входят средства для секционирования документов, для работы с перекрёстными ссылками и для набора сложных математических формул. Документы набираются на собственном языке разметки в виде обычных ASCII-файлов. Эти файлы транслируются специальной программой в файлы, «независимые от устройства», которые могут быть отображены на экране или напечатаны. Ядро TeX'a представляет собой язык низкоуровневой разметки, содержащий команды отступа и смены шрифта.

Каждый документ имеет три составляющие – содержание (смысловое наполнение), структуру и внешнее представление. Структура документа позволяет правильно определить составляющие его части и взаимоотношения между ними. Внешнее представление направлено на повышение эффективности восприятия информации читателем, что достигается за счет выделения смысловых частей документа теми или иными средствами, доступными для данной формы представления.

О разметке

В документе, помимо смыслового наполнения, должна содержаться некоторая метainформация, позволяющая определить его структуру и внешнее представление. Такая метainформация называется разметкой документа.

Разметка документа преследует следующие две основные цели:

- выделение смысловых частей (логических элементов) документа и связей между ними;
- указание действий, которые должны быть осуществлены с этими элементами.

Для достижения первой цели предназначена *структурная разметка*. Действия, направленные на получение внешнего представления, задаются *разметкой представления*.

В качестве примеров приведены два возможных способа разметки.

Пример 1

```
<div1 type="Section">
<head>Введение</head>
<p>Так уж сложилось, что большую часть информации человек
предпочитает хранить в виде документов...</p>
</div1>
```

Пример 2

```
<font face="Arial Bold" size=16>1. Введение<hspace size=20>  
<tab size=5><font face="Times New Roman" size=12>  
Так уж сложилось, что большую часть информации человек  
предпочитает хранить в виде документов...
```

В первом случае описан раздел, который имеет заголовок и текст в виде абзаца, то есть определяет структуру документа. Структурная разметка говорит о том, как текст устроен, то есть из каких он частей состоит, и как эти части друг с другом соотносятся.

Во втором случае показано, каким образом данный текст должен быть отображен на бумаге или на мониторе — выделить шрифтом Arial Bold размера 16, отступить по вертикали 20, сделать табуляцию 5, выделить шрифтом Times New Roman размера 12. Здесь мы имеем дело с разметкой представления документа, которая говорит о том, что делать с текстом, как его отображать.

Исторически разметка представления появилась раньше, и в течение длительного времени разметка документа была ориентирована исключительно на внешний (бумажный) вид документа. Но в последнее время ситуация существенно меняется — быстрый рост числа документов, их создание, хранение и использование в электронном виде, автоматизированная обработка и обмен документами предъявляют новые требования к разметке. В числе этих требований — независимость от среды представления, возможность осуществления эффективного поиска, возможность повторного использования как документа целиком, так и отдельных его элементов.

Быстрый рост количества документов привел к тому, что поиск нужной информации стал занимать все больше и больше времени. Например, если необходимо найти в Интернет информацию об авторе статей, то простой контекстный поиск даст огромное количество ссылок на те места, где встречается фамилия автора. После чего придется либо просмотреть все полученные ссылки, либо задавать дополнительную информацию для сужения области поиска. Если бы мы могли сразу указать, что фамилию следует искать только среди авторов журнальных статей технического плана, это во много раз упростило бы поиск. Но для этого необходимо, чтобы документы, среди которых ведется поиск, были размечены должным образом с явным выделением элементов "автор", "тематика" и т.п.

Возможность повторного использования документов или отдельных его частей приводит к тому, что мы не составляем каждый раз заново отчет или деловое письмо, используем в своей работе шаблоны контрактов, изменяя лишь некоторую существенную для данного случая информацию. Но делаем мы это преимущественно вручную. Если говорить об автоматизированном формировании, связывании, повторном использовании документов, то это становится возможным только тогда, когда документы как информационные объекты являются структурированными, а используемая метainформация полно и ясно описывает характеристики каждого элемента документа.

Все перечисленные задачи можно решить, используя исключительно структурный подход при разметке документов. Именно структурная разметка позволяет выделять смысловые элементы, определять их связи с другими элементами как в рамках одного документа, так и вне этих рамок.

Характерной особенностью многих языков разметки является блочная структура всего документа. Концепция следующая: документ – это блок, который состоит из блоков, которые в свою очередь состоят из блоков и т.д.

Блок		Блок		Блок
		Блок	Блок	
Блок	Блок		Блок	
	Блок		Блок	
Блок	Блок	Блок		

Разметка текста осуществляется с помощью специальных управляющих кодов, присутствующих в документе. Одним из вариантов таких кодов являются **тэги (tag)**. Тэги представляют собой ключевые слова, описывающие структуру разметки. Кроме того, тэги могут иметь *атрибуты*, которые задают разметку представления. Например

`<center color=red background=black>` Текст красного цвета на чёрном фоне в центре страницы `</center>`

Тэги `<center></center>` образуют логические скобки, которые задают вывод заключённого между ними текста в центре. Тэг имеет атрибуты `color` и `background`, которые задают цвет текста и фона соответственно.

Вложенность блоков. Как уже упоминалось, языки разметки имеют блочную структуру. Предположим, что есть пара тэгов `<block> </block>`, задающих блок, и теги `<row> </row>` и `<column> </column>`, задающие строку и столбец в этих блоках. Тогда структура, представленная на рис. 1, может иметь следующий вид

A	B	E
C	D	
F		

Рис 1

```

<block>
  <column>
    <row>
      <block>
        <row>
          <column> A </column>
          <column> B </column>
        </row>
        <column> C </column>
        <column> D </column>
      </row>
    </row>
  </block>
</column>
  <row> F </row>
</block>

```

<column> E </column>
</block>

Спецификация языка разметки eMark

Данный язык разметки предназначен для оформления вывода текста на стандартную консоль, которая имеет 24 строки по 80 символов каждая. Соответственно страница выводимого текста может содержать максимум 24 строки и 80 столбцов. Поддерживаемые тэги и их атрибуты:

1. <block rows=число columns=число> </block>
атрибуты rows и columns задают число строк и столбцов в текущем блоке
2. <column valign=вертикальное_выравнивание
halign=горизонтальное_выравнивание textcolor=цвет bgcolor=цвет
width=число> </column>
вертикальное_выравнивание – одно из значений top, center, bottom
(выравнивание по верхнему краю, по центру и по нижнему краю соответственно)
горизонтальное_выравнивание – одно из значений left, center, right
(выравнивание по левому краю, по центру и по правому краю соответственно)
цвет – цифра от 0 до 15 включительно, соответствующая одному из цветов, в которые может быть раскрашена консоль
число – ширина столбца в символах
3. <row valign=вертикальное_выравнивание
halign=горизонтальное_выравнивание textcolor=цвет bgcolor=цвет
height=число> </row>
смысл атрибутов аналогичен одноимённым атрибутам тэга <column>.
Атрибут height задаёт высоту строки как количество строчек консоли
Дополнительные условия и ограничения:
 1. Документ должен состоять как минимум из одного тэга <block>
 2. Атрибуты rows и columns тэга <block> обязательны и не могут быть больше высоты (ширины) элемента, в который данный тэг вложен
 3. Количество вложенных тэгов <column> и <row> для каждого тэга <block> должно соответствовать значению атрибутов columns и rows
 4. Значения по умолчанию для тегов:
 - valign = top
 - halign = left
 - textcolor = 15 (белый)
 - bgcolor = 0 (чёрный)
 - width (только для последнего тэга <column> в тэге <block>, для остальных должно быть указано явно) равно значению ширины блока за вычетом суммы ширин всех предыдущих столбцов в блоке
 - height (только для последнего тэга <row> в тэге <block>, для остальных должно быть указано явно) равно значению высоты блока за вычетом суммы высот всех предыдущих строк в блоке
 - columns = 1 и rows = 0 только для внешнего тэга <block>, для остальных должно быть указано явно
 5. Каждому тэгу должен соответствовать закрывающий тэг

Пример простейшего документа на языке разметки eMark:

```
<block>  
  <column>"Hellow world" example using eMark</column>  
</block>
```

Задание на лабораторную работу

Написать процессор, обрабатывающий документы на языке eMark.

Входные данные: текстовый файл, содержащий документ на языке eMark.

Выходные данные: консоль с отформатированным текстом в соответствии с управляющими инструкциями, либо с сообщениями об ошибках в документе